# Промышленное машинное обучение на Spark

Лекция 6: Spark ML

| 01 |
|----|
| 02 |
| 03 |
| 04 |
| 05 |
|    |
| 07 |
| 08 |

Оборачиваем модель в сервис. Первая часть: Docker. Flask

Оборачиваем модель в сервис. Вторая часть: Requests. REST API

Распределенные вычисления. HDFS. MapReduce. Spark DataFrame

Погружение в среду Spark. RDD, SQL, Pandas API.

Генерация признаков. Spark feature engineering


Распределенное обучение моделей. Spark ML


Обработка и хранение текстовых данных и картинок. Spark image processing. Spark NLP.

Обработка потоковых данных. Spark Streaming.


## Что позволяет Spark.ML

http://spark.apache.org/docs/latest/ml-features.html






## **Spark ML Workflow**




## Pipeline



#### **Transformers**

- Tokenizer
- StopWordsRemover
- n-gram
- Binarizer
- PCA
- PolynomialExpansion
- Discrete Cosine Transform (DCT)
- StringIndexer
- IndexToString
- OneHotEncoder
- VectorIndexer
- Interaction



- Normalizer
- StandardScaler
- RobustScaler
- MinMaxScaler
- MaxAbsScaler
- Bucketizer
- ElementwiseProduct
- SQLTransformer
- VectorAssembler
- VectorSizeHint
- QuantileDiscretizer
- Imputer

#### **Estimators**

- LogisticRegression
- DecisionTreeClassifier
- RandomForestClassifier
- NaiveBayes
- OneVsRest
- MultilayerPerceptronClassifier

- KMeans
- LDA
- GaussianMixture
- ALS
- DecisionTreeRegressor
- LinearRegression
- RandomForestRegressor

### **Evaluators**

- BinaryClassificationEvaluator
- RegressionEvaluator
- MulticlassClassificationEvaluator
- MultilabelClassificationEvaluator
- ClusteringEvaluator